

Laboratorio 1. Series de tiempo

Nina Nájera Marakovits

Carné 231088

CC3084 Data Science

Semestre II 2026

Objetivo

El objetivo es analizar el ingreso mensual de viajeros internacionales a Guatemala y comparar varios modelos de pronóstico.

Para mantener una comparación válida durante todo el período se utilizan únicamente Turista y Excursionista. Se analiza la serie total, las tres vías de ingreso y las tres regiones con mayor cantidad acumulada de viajeros.

Preparación

Primero se debe instalar las librerías, están en el requirements.

Importing plotly failed. Interactive plots will not work.

Raíz del proyecto: C:\Users\ninan\OneDrive\Documentos\Escritorio\UVG\VIII SEMESTRE\Data Science\Data_Science

Archivo de datos: C:\Users\ninan\OneDrive\Documentos\Escritorio\UVG\VIII SEMESTRE\Data Science\Data_Science\data\raw\Base_Migracion_2009-2026jun.xlsx

Prophet disponible: True

Carga y limpieza de datos

La fecha se construye con el año y el código del mes. La cantidad de viajeros se convierte a número. Los registros sin fecha o sin cantidad de viajeros no pueden utilizarse en las series y se eliminan únicamente para el análisis temporal.

Filas originales: 161,036

Columnas originales: 13

Período: 2009-01 a 2026-06

	Año	Mes cod	Mes	Vía	Frontera	País	Región	Región dos	Regiones OMT	MCEO	Agrupación Residencia
0	2009	1	Ene	Aérea	01 La Aurora	Albania	OTROS EUROPEOS	Europa	EUROPA MERIDIONAL	08 OTROS	Europa
1	2009	1	Ene	Aérea	01 La Aurora	Alemania	EUROPA	Europa	EUROPA OCCIDENTAL	04 EUROPA	Europa
2	2009	1	Ene	Aérea	01 La Aurora	Angola	OTROS PAISES DEL MUNDO	Otros Países Del Mundo	ÁFRICA CENTRAL	08 OTROS	Resto del Mundo
3	2009	1	Ene	Aérea	01 La Aurora	Arabia Saudita	OTROS ORIENTE MEDIO	Oriente Medio	ORIENTE MEDIO	08 OTROS	Resto del Mundo
4	2009	1	Ene	Aérea	01 La Aurora	Argelia	OTROS PAISES DEL MUNDO	Otros Países Del Mundo	ÁFRICA DEL NORTE	08 OTROS	Resto del Mundo


Análisis de calidad

Se revisan valores faltantes, duplicados y posibles valores atípicos. Los valores atípicos no se eliminan de forma automática porque pueden representar meses, fronteras o mercados con una cantidad realmente alta de viajeros.

	Indicador	Valor
0	Filas originales	161036
1	Valores faltantes	0
2	Duplicados exactos	0
3	Registros con cero viajeros	54
4	Posibles atípicos según IQR	26390

Valores faltantes por columna

Valores faltantes



Selección de registros comparables

La categoría Viajero cambia entre 2022 y 2023. Para evitar una caída causada por el cambio de definición se utilizan Turista y Excursionista durante todo el período.

Viajeros


Tipo de Viajero

Turista	37,642,728.550
Excursionista	9,069,184.336
Viajero	4,471,622.207
Cruceristas	1,104,402.000

Filas utilizadas: 137,642
Viajeros acumulados: 46,711,913

Análisis exploratorio

Se revisa el comportamiento mensual y anual. También se identifican los países, regiones, vías y fronteras con mayor cantidad acumulada de viajeros.



Viajeros**Fecha**

2009-01-01	1,880,182.852
2010-01-01	2,004,783.999
2011-01-01	2,079,714.603
2012-01-01	2,139,541.481
2013-01-01	2,289,702.752
2014-01-01	2,660,177.317
2015-01-01	2,917,886.040
2016-01-01	2,997,026.744
2017-01-01	3,307,651.287
2018-01-01	3,793,760.857
2019-01-01	4,132,250.602
2020-01-01	1,059,770.432
2021-01-01	1,098,964.379
2022-01-01	3,229,328.600
2023-01-01	2,917,826.811
2024-01-01	3,274,435.995
2025-01-01	3,352,288.658
2026-01-01	1,576,619.476

Cambio de 2020 frente a 2019: -74.35 por ciento
El año 2026 contiene únicamente datos de enero a junio.

Países o mercados con más viajeros

Viajeros

País	
El Salvador	14,079,135.771
Guatemala	13,870,391.348
Estados Unidos de América	6,965,679.710
Honduras	2,520,974.307
México	1,678,422.551
Belice	916,101.075
Costa Rica	860,240.685
Nicaragua	811,145.393
Colombia	549,494.686
Canadá	516,707.890

Regiones con más viajeros

Viajeros

Región dos	
América Del Centro	33,283,931.980
América Del Norte	9,160,810.151
Europa	2,149,271.065
América Del Sur y el Caribe	1,413,590.324
Asia	410,333.513
Oceanía	135,505.366
Oriente Medio	133,735.192
Otros Paises Del Mundo	23,914.295
0	821.000

Vías de ingreso


Viajeros



Vía	
Terrestre	27,592,253.333
Aérea	19,019,418.554
Marítima	100,241.000


Fronteras más utilizadas

Viajeros

Frontera	
01 La Aurora	18,989,984.615
07 Valle Nuevo	10,143,045.315
09 San Cristóbal	4,183,631.706
08 Pedro de Alvarado	3,764,229.263
10 La Ermita (Nueva Anguiatú)	2,587,072.270
20 Melchor de Mencos	1,782,864.385
13 El Cinchado / El Corinto	1,213,485.141
11 Agua Caliente	922,419.528
12 El Florido	910,373.467
15 El Carmen	852,663.132







Estadísticas descriptivas

La media resume el nivel promedio. La desviación estándar y el coeficiente de variación ayudan a comparar la dispersión entre series con tamaños distintos.

Viajero	
count	137,642.000
mean	339.373
std	2,515.138
min	0.000
25%	2.000
50%	7.000
75%	37.000
90%	259.134
95%	881.000
99%	6,232.770
max	83,511.000

División de entrenamiento y prueba

La división respeta el orden del tiempo. Los primeros meses forman el conjunto de entrenamiento y los últimos meses forman el conjunto de prueba.

Meses totales: 210
Entrenamiento: 147 meses
Inicio de entrenamiento: 2009-01
Fin de entrenamiento: 2021-03
Prueba: 63 meses
Inicio de prueba: 2021-04
Fin de prueba: 2026-06

Construcción de las series

Se construyen siete series mensuales.

1. Total mensual
2. Vía aérea
3. Vía terrestre
4. Vía marítima
5. América Del Centro
6. América Del Norte
7. Europa

Las tres regiones se seleccionan con el total acumulado de todo el período.

	Inicio	Fin	Frecuencia	Observaciones	Media	Desviación estándar	Coeficiente de variación
Serie							
Total	2009-01	2026-06	Mensual	210	222,437.680	84,724.939	0.381
Vía Aérea	2009-01	2026-06	Mensual	210	90,568.660	27,855.303	0.308
Vía Terrestre	2009-01	2026-06	Mensual	210	131,391.683	60,815.995	0.463
Vía Marítima	2009-01	2026-06	Mensual	210	477.338	541.260	1.134
Región América Del Centro	2009-01	2026-06	Mensual	210	158,494.914	66,477.133	0.419
Región América Del Norte	2009-01	2026-06	Mensual	210	43,622.905	17,881.103	0.410
Región Europa	2009-01	2026-06	Mensual	210	10,234.624	4,401.300	0.430

Regiones seleccionadas
América Del Centro
América Del Norte
Europa

Análisis de estacionariedad


Para cada serie se revisa el gráfico, la descomposición, la media móvil, la desviación móvil, la ACF, la PACF y la prueba Dickey Fuller aumentada.

Se usa logaritmo de uno más la serie para reducir cambios grandes en la varianza. Después se revisa si hace falta una diferencia normal y una diferencia estacional de doce meses.


=====


Total

=====



Descomposición de Total





Inicio: 2009-01

Fin: 2026-06

Frecuencia: mensual con doce observaciones por año

Fuerza estacional: 0.180

Fuerza de tendencia: 0.532

Lambda Box Cox: 0.991

Valor sugerido de d: 1

Valor sugerido de D: 0

Valor inicial de p: 1

Valor inicial de q: 1


	Transformación	p valor ADF	Conclusión
0	Original	0.152	No estacionaria en media
1	Logaritmo	0.116	No estacionaria en media
2	Primera diferencia	0.028	Estacionaria en media
3	Diferencia estacional	0.964	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media

La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.




=====


Vía Aérea

=====



Descomposición de Vía Aérea






Inicio: 2009-01
Fin: 2026-06
Frecuencia: mensual con doce observaciones por año
Fuerza estacional: 0.142
Fuerza de tendencia: 0.259
Lambda Box Cox: 1.257
Valor sugerido de d: 1
Valor sugerido de D: 0
Valor inicial de p: 1
Valor inicial de q: 1



	Transformación	p valor ADF	Conclusión
0	Original	0.151	No estacionaria en media
1	Logaritmo	0.273	No estacionaria en media
2	Primera diferencia	0.027	Estacionaria en media
3	Diferencia estacional	0.850	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media


La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.

Vía Terrestre



Descomposición de Vía Terrestre






Inicio: 2009-01
 Fin: 2026-06
 Frecuencia: mensual con doce observaciones por año
 Fuerza estacional: 0.185
 Fuerza de tendencia: 0.714
 Lambda Box Cox: 0.761
 Valor sugerido de d: 1
 Valor sugerido de D: 0
 Valor inicial de p: 1
 Valor inicial de q: 1



	Transformación	p valor ADF	Conclusión
0	Original	0.238	No estacionaria en media
1	Logaritmo	0.277	No estacionaria en media
2	Primera diferencia	0.025	Estacionaria en media
3	Diferencia estacional	0.932	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media


La serie no es estacionaria en media y necesita diferenciación.
 La estacionalidad es débil y se probarán modelos con menor parte estacional.

Vía Marítima



Descomposición de Vía Marítima






Inicio: 2009-01
Fin: 2026-06
Frecuencia: mensual con doce observaciones por año
Fuerza estacional: 0.073
Fuerza de tendencia: 0.972
Lambda Box Cox: 0.269
Valor sugerido de d: 1
Valor sugerido de D: 0
Valor inicial de p: 1
Valor inicial de q: 1

	Transformación	p valor ADF	Conclusión
0	Original	0.847	No estacionaria en media
1	Logaritmo	0.832	No estacionaria en media
2	Primera diferencia	0.000	Estacionaria en media
3	Diferencia estacional	0.259	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media


La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.

Región América Del Centro




Descomposición de Región América Del Centro


América Del Centro




Media móvil de Región América Del Centro



Desviación móvil de Región América Del Centro






Inicio: 2009-01
Fin: 2026-06
Frecuencia: mensual con doce observaciones por año
Fuerza estacional: 0.180
Fuerza de tendencia: 0.578
Lambda Box Cox: 0.816
Valor sugerido de d: 1
Valor sugerido de D: 0
Valor inicial de p: 2
Valor inicial de q: 2




	Transformación	p valor ADF	Conclusión
0	Original	0.213	No estacionaria en media
1	Logaritmo	0.200	No estacionaria en media
2	Primera diferencia	0.036	Estacionaria en media
3	Diferencia estacional	0.972	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media


La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.

Región América Del Norte



Descomposición de Región América Del Norte






Inicio: 2009-01
Fin: 2026-06
Frecuencia: mensual con doce observaciones por año
Fuerza estacional: 0.113
Fuerza de tendencia: 0.142
Lambda Box Cox: 0.931
Valor sugerido de d: 1
Valor sugerido de D: 0
Valor inicial de p: 1
Valor inicial de q: 1



	Transformación	p valor ADF	Conclusión
0	Original	0.010	Estacionaria en media
1	Logaritmo	0.158	No estacionaria en media
2	Primera diferencia	0.049	Estacionaria en media
3	Diferencia estacional	0.939	No estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media


La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.

Región Europa



Descomposición de Región Europa





Inicio: 2009-01
Fin: 2026-06
Frecuencia: mensual con doce observaciones por año
Fuerza estacional: 0.176
Fuerza de tendencia: 0.316
Lambda Box Cox: 0.963
Valor sugerido de d: 1
Valor sugerido de D: 0
Valor inicial de p: 1
Valor inicial de q: 1

	Transformación	p valor ADF	Conclusión
0	Original	0.122	No estacionaria en media
1	Logaritmo	0.285	No estacionaria en media
2	Primera diferencia	0.114	No estacionaria en media
3	Diferencia estacional	0.002	Estacionaria en media
4	Primera diferencia y diferencia estacional	0.000	Estacionaria en media

La serie no es estacionaria en media y necesita diferenciación.
La estacionalidad es débil y se probarán modelos con menor parte estacional.

	Fuerza estacional	Fuerza de tendencia	Lambda Box Cox	ADF original	ADF log	p sugerido	d sugerido	q sugerido	D sugerido
Serie									
Total	0.180	0.532	0.991	0.152	0.116	1	1	1	0
Vía Aérea	0.142	0.259	1.257	0.151	0.273	1	1	1	0
Vía Terrestre	0.185	0.714	0.761	0.238	0.277	1	1	1	0
Vía Marítima	0.073	0.972	0.269	0.847	0.832	1	1	1	0
Región América Del Centro	0.180	0.578	0.816	0.213	0.200	2	1	2	0
Región América Del Norte	0.113	0.142	0.931	0.010	0.158	1	1	1	0
Región Europa	0.176	0.316	0.963	0.122	0.285	1	1	1	0

Modelos de pronóstico

Para cada serie se comparan varios modelos SARIMA, Holt Winters, suavizamiento exponencial simple, seasonal naive y Prophet.

Los modelos SARIMA trabajan con el logaritmo de la serie. Sus predicciones se regresan a la escala original antes de calcular los errores.

El mejor SARIMA se selecciona con AIC y BIC. El mejor modelo general se selecciona principalmente con RMSE y se revisa también el MAE.


=====
Total
=====
Comparación de modelos SARIMA


	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	197,448.997	209,747.887	77.161	85.854
1	SARIMA (1, 1, 1) x (1, 0, 0, 12)	196,817.166	209,111.679	79.460	91.021
2	SARIMA (1, 1, 1) x (0, 0, 1, 12)	162,379.980	175,899.616	88.639	100.170
3	SARIMA (2, 1, 1) x (0, 0, 1, 12)	164,587.054	178,225.217	90.185	104.599
4	SARIMA (1, 1, 2) x (0, 0, 1, 12)	164,381.044	178,042.912	90.775	105.151

22:20:30 - cmdstanpy - INFO - Chain [1] start processing
22:20:30 - cmdstanpy - INFO - Chain [1] done processing
Comparación general

	Modelo	MAE	RMSE	AIC	BIC
0	Prophet	132,304.568	139,548.877	NaN	NaN
1	SARIMA (1, 1, 1) x (0, 0, 1, 12)	162,379.980	175,899.616	88.639	100.170
2	SARIMA (1, 1, 2) x (0, 0, 1, 12)	164,381.044	178,042.912	90.775	105.151
3	SARIMA (2, 1, 1) x (0, 0, 1, 12)	164,587.054	178,225.217	90.185	104.599
4	Suavizamiento exponencial simple	165,372.541	180,598.233	NaN	NaN
5	SARIMA (1, 1, 1) x (1, 0, 0, 12)	196,817.166	209,111.679	79.460	91.021
6	SARIMA (0, 1, 1) x (1, 0, 0, 12)	197,448.997	209,747.887	77.161	85.854
7	Seasonal naive	207,321.637	219,663.869	NaN	NaN
8	Holt Winters	224,794.346	241,513.187	NaN	NaN

Mejor SARIMA según AIC y BIC: SARIMA (0, 1, 1) x (1, 0, 0, 12)
Mejor modelo según RMSE: Prophet





	lb_stat	lb_pvalue
12	9.907	0.624

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

Vía Aérea

Comparación de modelos SARIMA




	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	42,873.544	48,869.671	196.900	205.593
1	SARIMA (1, 1, 1) x (1, 0, 0, 12)	41,537.954	47,551.610	198.038	209.600
2	SARIMA (1, 1, 1) x (0, 0, 1, 12)	31,483.389	36,548.987	200.544	212.075
3	SARIMA (1, 1, 2) x (0, 0, 1, 12)	34,563.152	39,465.243	201.446	215.822
4	SARIMA (2, 1, 1) x (0, 0, 1, 12)	35,296.482	40,166.118	201.677	216.091

22:20:31 - cmdstanpy - INFO - Chain [1] start processing
22:20:32 - cmdstanpy - INFO - Chain [1] done processing

Comparación general

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (1, 1, 1) x (0, 0, 1, 12)	31,483.389	36,548.987	200.544	212.075
1	SARIMA (1, 1, 2) x (0, 0, 1, 12)	34,563.152	39,465.243	201.446	215.822
2	SARIMA (2, 1, 1) x (0, 0, 1, 12)	35,296.482	40,166.118	201.677	216.091
3	Suavizamiento exponencial simple	36,970.596	42,141.220	NaN	NaN
4	Prophet	41,300.514	45,687.741	NaN	NaN
5	SARIMA (1, 1, 1) x (1, 0, 0, 12)	41,537.954	47,551.610	198.038	209.600
6	SARIMA (0, 1, 1) x (1, 0, 0, 12)	42,873.544	48,869.671	196.900	205.593
7	Holt Winters	59,525.620	64,260.307	NaN	NaN
8	Seasonal naive	75,512.726	79,339.803	NaN	NaN

Mejor SARIMA según AIC y BIC: SARIMA (0, 1, 1) x (1, 0, 0, 12)
Mejor modelo según RMSE: SARIMA (1, 1, 1) x (0, 0, 1, 12)



lb_stat **lb_pvalue**

12 8.449 0.749

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

Vía Terrestre

Comparación de modelos SARIMA

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	141,003.527	152,850.854	112.787	121.481
1	SARIMA (1, 1, 1) x (1, 0, 0, 12)	141,488.036	153,326.451	114.507	126.069
2	SARIMA (1, 1, 1) x (0, 0, 1, 12)	129,885.387	141,867.983	123.435	134.966
3	SARIMA (2, 1, 1) x (0, 0, 1, 12)	125,667.999	137,882.771	123.970	138.384
4	SARIMA (1, 1, 2) x (0, 0, 1, 12)	127,826.803	139,969.119	124.214	138.590



22:20:33 - cmdstanpy - INFO - Chain [1] start processing

22:20:33 - cmdstanpy - INFO - Chain [1] done processing

Comparación general

	Modelo	MAE	RMSE	AIC	BIC
0	Prophet	47,712.983	57,657.637	NaN	NaN
1	Suavizamiento exponencial simple	121,715.510	134,136.097	NaN	NaN
2	Holt Winters	123,748.611	134,151.113	NaN	NaN
3	SARIMA (2, 1, 1) x (0, 0, 1, 12)	125,667.999	137,882.771	123.970	138.384
4	SARIMA (1, 1, 2) x (0, 0, 1, 12)	127,826.803	139,969.119	124.214	138.590
5	SARIMA (1, 1, 1) x (0, 0, 1, 12)	129,885.387	141,867.983	123.435	134.966
6	Seasonal naive	132,209.038	144,274.981	NaN	NaN
7	SARIMA (0, 1, 1) x (1, 0, 0, 12)	141,003.527	152,850.854	112.787	121.481
8	SARIMA (1, 1, 1) x (1, 0, 0, 12)	141,488.036	153,326.451	114.507	126.069

Mejor SARIMA según AIC y BIC: SARIMA (0, 1, 1) x (1, 0, 0, 12)
Mejor modelo según RMSE: Prophet



	lb_stat	lb_pvalue
12	10.199	0.599

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

=====

Vía Marítima

=====

Comparación de modelos SARIMA

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	0.000	0.000	257.751	266.445
1	SARIMA (1, 1, 1) x (0, 0, 1, 12)	0.000	0.000	257.839	269.370
2	SARIMA (1, 1, 1) x (1, 0, 0, 12)	0.000	0.000	258.813	270.375
3	SARIMA (1, 1, 2) x (0, 0, 1, 12)	0.000	0.000	258.834	273.210
4	SARIMA (2, 1, 1) x (0, 0, 1, 12)	0.000	0.000	259.700	274.114

22:20:34 - cmdstanpy - INFO - Chain [1] start processing

22:20:34 - cmdstanpy - INFO - Chain [1] done processing


Comparación general


	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	0.000	0.000	257.751	266.445
1	SARIMA (1, 1, 1) x (1, 0, 0, 12)	0.000	0.000	258.813	270.375
2	Seasonal naive	0.000	0.000	NaN	NaN
3	Prophet	0.000	0.000	NaN	NaN
4	Suavizamiento exponencial simple	0.000	0.000	NaN	NaN
5	SARIMA (2, 1, 1) x (0, 0, 1, 12)	0.000	0.000	259.700	274.114
6	SARIMA (1, 1, 2) x (0, 0, 1, 12)	0.000	0.000	258.834	273.210
7	SARIMA (1, 1, 1) x (0, 0, 1, 12)	0.000	0.000	257.839	269.370
8	Holt Winters	2.091	10.767	NaN	NaN

Mejor SARIMA según AIC y BIC: SARIMA (0, 1, 1) x (1, 0, 0, 12)

Mejor modelo según RMSE: SARIMA (0, 1, 1) x (1, 0, 0, 12)

Predicción para Vía Marítima





	lb_stat	lb_pvalue
12	0.579	1.000

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

=====

Región América Del Centro

=====

Comparación de modelos SARIMA

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (0, 1, 1) x (1, 0, 0, 12)	139,836.336	149,828.557	64.362	73.056
1	SARIMA (2, 1, 2) x (1, 0, 0, 12)	141,082.044	151,051.773	69.794	87.091
2	SARIMA (2, 1, 2) x (0, 0, 1, 12)	121,084.093	132,185.470	72.607	89.858
3	SARIMA (1, 1, 1) x (0, 0, 1, 12)	115,353.637	125,991.096	79.553	91.084
4	SARIMA (2, 1, 1) x (0, 0, 1, 12)	115,368.273	126,147.680	80.474	94.888
5	SARIMA (1, 1, 2) x (0, 0, 1, 12)	114,754.813	125,560.746	80.704	95.080




22:20:35 - cmdstanpy - INFO - Chain [1] start processing

22:20:35 - cmdstanpy - INFO - Chain [1] done processing

Comparación general

	Modelo	MAE	RMSE	AIC	BIC
0	Prophet	62,484.796	67,837.611	NaN	NaN
1	Suavizamiento exponencial simple	109,866.650	121,961.448	NaN	NaN
2	SARIMA (1, 1, 2) x (0, 0, 1, 12)	114,754.813	125,560.746	80.704	95.080
3	SARIMA (1, 1, 1) x (0, 0, 1, 12)	115,353.637	125,991.096	79.553	91.084
4	SARIMA (2, 1, 1) x (0, 0, 1, 12)	115,368.273	126,147.680	80.474	94.888
5	SARIMA (2, 1, 2) x (0, 0, 1, 12)	121,084.093	132,185.470	72.607	89.858
6	Seasonal naive	134,400.175	144,899.303	NaN	NaN
7	SARIMA (0, 1, 1) x (1, 0, 0, 12)	139,836.336	149,828.557	64.362	73.056
8	SARIMA (2, 1, 2) x (1, 0, 0, 12)	141,082.044	151,051.773	69.794	87.091
9	Holt Winters	149,160.999	160,928.551	NaN	NaN

Mejor SARIMA según AIC y BIC: SARIMA (0, 1, 1) x (1, 0, 0, 12)
Mejor modelo según RMSE: Prophet



	lb_stat	lb_pvalue
12	11.406	0.494

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

=====

Región América Del Norte

=====

Comparación de modelos SARIMA

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (1, 1, 2) x (0, 0, 1, 12)	38,116.430	42,152.886	405.541	419.917
1	SARIMA (2, 1, 1) x (0, 0, 1, 12)	37,721.449	41,879.093	408.455	422.869
2	SARIMA (1, 1, 1) x (0, 0, 1, 12)	28,764.645	32,925.075	411.604	423.135
3	SARIMA (1, 1, 1) x (1, 0, 0, 12)	34,508.521	38,124.795	411.925	423.486
4	SARIMA (0, 1, 1) x (1, 0, 0, 12)	37,052.427	40,493.577	412.280	420.974

22:20:36 - cmdstanpy - INFO - Chain [1] start processing

22:20:36 - cmdstanpy - INFO - Chain [1] done processing


Comparación general


	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (1, 1, 1) x (0, 0, 1, 12)	28,764.645	32,925.075	411.604	423.135
1	SARIMA (1, 1, 1) x (1, 0, 0, 12)	34,508.521	38,124.795	411.925	423.486
2	SARIMA (0, 1, 1) x (1, 0, 0, 12)	37,052.427	40,493.577	412.280	420.974
3	SARIMA (2, 1, 1) x (0, 0, 1, 12)	37,721.449	41,879.093	408.455	422.869
4	SARIMA (1, 1, 2) x (0, 0, 1, 12)	38,116.430	42,152.886	405.541	419.917
5	Prophet	39,112.832	44,175.902	NaN	NaN
6	Suavizamiento exponencial simple	39,603.739	44,300.517	NaN	NaN
7	Seasonal naive	49,974.108	53,533.367	NaN	NaN
8	Holt Winters	49,534.801	54,187.694	NaN	NaN

Mejor SARIMA según AIC y BIC: SARIMA (1, 1, 2) x (0, 0, 1, 12)

Mejor modelo según RMSE: SARIMA (1, 1, 1) x (0, 0, 1, 12)

Predicción para Región América Del Norte





lb_stat lb_pvalue

12 13.201 0.355

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

Región Europa

Comparación de modelos SARIMA

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (2, 1, 1) x (0, 0, 1, 12)	9,396.071	10,642.486	341.750	356.164
1	SARIMA (0, 1, 1) x (1, 0, 0, 12)	11,303.780	12,449.437	342.698	351.391
2	SARIMA (1, 1, 1) x (1, 0, 0, 12)	11,239.973	12,374.658	343.013	354.574
3	SARIMA (1, 1, 1) x (0, 0, 1, 12)	9,153.821	10,394.796	347.088	358.619
4	SARIMA (1, 1, 2) x (0, 0, 1, 12)	9,262.626	10,502.724	347.491	361.867

22:20:37 - cmdstanpy - INFO - Chain [1] start processing
22:20:37 - cmdstanpy - INFO - Chain [1] done processing


Comparación general

	Modelo	MAE	RMSE	AIC	BIC
0	SARIMA (1, 1, 1) x (0, 0, 1, 12)	9,153.821	10,394.796	347.088	358.619
1	SARIMA (1, 1, 2) x (0, 0, 1, 12)	9,262.626	10,502.724	347.491	361.867
2	SARIMA (2, 1, 1) x (0, 0, 1, 12)	9,396.071	10,642.486	341.750	356.164
3	Suavizamiento exponencial simple	9,571.367	10,978.122	NaN	NaN
4	Prophet	10,118.838	11,538.135	NaN	NaN
5	Seasonal naive	11,075.465	12,134.507	NaN	NaN
6	SARIMA (1, 1, 1) x (1, 0, 0, 12)	11,239.973	12,374.658	343.013	354.574
7	SARIMA (0, 1, 1) x (1, 0, 0, 12)	11,303.780	12,449.437	342.698	351.391
8	Holt Winters	11,507.563	12,765.099	NaN	NaN


Mejor SARIMA según AIC y BIC: SARIMA (2, 1, 1) x (0, 0, 1, 12)

Mejor modelo según RMSE: SARIMA (1, 1, 1) x (0, 0, 1, 12)


Predicción para Región Europa



Residuos de SARIMA (2, 1, 1) x (0, 0, 1, 12)



ACF de residuos



lb_stat **lb_pvalue**

12 14.487 0.271

No se detecta autocorrelación importante en los residuos al nivel de cinco por ciento.

Serie	Mejor modelo	MAE	RMSE	Mejor SARIMA	AIC mejor SARIMA	BIC mejor SARIMA	p valor Ljung Box
Total	Prophet	132,304.568	139,548.877	SARIMA (0, 1, 1) x (1, 0, 0, 12)	77.161	85.854	0.624
Vía Aérea	SARIMA (1, 1, 1) x (0, 0, 1, 12)	31,483.389	36,548.987	SARIMA (0, 1, 1) x (1, 0, 0, 12)	196.900	205.593	0.749
Vía Terrestre	Prophet	47,712.983	57,657.637	SARIMA (0, 1, 1) x (1, 0, 0, 12)	112.787	121.481	0.599
Vía Marítima	SARIMA (0, 1, 1) x (1, 0, 0, 12)	0.000	0.000	SARIMA (0, 1, 1) x (1, 0, 0, 12)	257.751	266.445	1.000
Región América Del Centro	Prophet	62,484.796	67,837.611	SARIMA (0, 1, 1) x (1, 0, 0, 12)	64.362	73.056	0.494
Región América Del Norte	SARIMA (1, 1, 1) x (0, 0, 1, 12)	28,764.645	32,925.075	SARIMA (1, 1, 2) x (0, 0, 1, 12)	405.541	419.917	0.355
Región Europa	SARIMA (1, 1, 1) x (0, 0, 1, 12)	9,153.821	10,394.796	SARIMA (2, 1, 1) x (0, 0, 1, 12)	341.750	356.164	0.271

Análisis comparativo

La estacionalidad se mide con la proporción de variación explicada por el componente estacional. La tendencia se resume con el cambio anual aproximado del logaritmo de la serie. La volatilidad se compara con el coeficiente de variación. El efecto de la pandemia se calcula con el cambio de 2020 frente a 2019.

Serie	Fuerza estacional	Crecimiento anual aproximado	Coefficiente de variación	Cambio 2020 frente a 2019
Total	0.256	1.283	0.381	-74.354
Vía Aérea	0.163	-0.465	0.308	-72.797
Vía Terrestre	0.230	2.130	0.463	-75.225
Vía Marítima	0.051	-44.653	1.134	NaN
Región América Del Centro	0.263	1.135	0.419	-74.431
Región América Del Norte	0.083	-0.135	0.410	-74.144
Región Europa	0.211	-1.957	0.430	-71.830

Mayor estacionalidad: Región América Del Centro

Mayor tendencia de crecimiento: Vía Terrestre

Mayor volatilidad: Vía Marítima

Mayor caída durante la pandemia: Vía Terrestre

Descubrimientos útiles para INGUAT

Los siguientes mensajes se generan con los resultados del análisis.

La vía con mayor volumen acumulado es Terrestre. Esto ayuda a priorizar personal, infraestructura y campañas en los puntos relacionados con esa vía.

La región que más viajeros aporta es América Del Centro. Puede considerarse como un mercado principal para promoción turística.

El mes con el componente estacional más alto en la serie total es diciembre. Conviene preparar capacidad antes de ese mes.

La serie más afectada por la pandemia fue Vía Terrestre. Esta serie necesita planes de recuperación y seguimiento especial.

Los modelos con menor RMSE pueden utilizarse para planificar personal, transporte, atención y campañas con varios meses de anticipación.

Conclusiones

El conjunto de datos presenta tendencia, estacionalidad y un cambio fuerte durante la pandemia. Por esta razón un modelo que incluya tendencia y estacionalidad suele ser más útil que un promedio simple.

La transformación logarítmica ayuda a estabilizar la varianza. La prueba Dickey Fuller, la ACF y la PACF permiten definir las diferencias y los parámetros iniciales de los modelos SARIMA.

La selección final se realiza con las métricas del conjunto de prueba. El RMSE penaliza con mayor fuerza los errores grandes y el MAE muestra el error promedio en viajeros. AIC y BIC se utilizan para comparar

únicamente los modelos SARIMA.

Las conclusiones finales deben leerse junto con las tablas generadas porque el mejor modelo puede ser diferente para cada serie.

Archivos generados

Las figuras y tablas se guardan en data/processed/

Archivos generados

data\processed\.gitkeep
data\processed\figures\01_boxplot_viajero.png
data\processed\figures\02_total_mensual.png
data\processed\figures\03_total_anual.png
data\processed\figures\04_top_paises.png
data\processed\figures\05_top_regiones.png
data\processed\figures\06_vias_ingreso.png
data\processed\figures\07_top_fronteras.png
data\processed\figures\acf_pacf_región_america_del_centro.png
data\processed\figures\acf_pacf_región_america_del_norte.png
data\processed\figures\acf_pacf_región_europa.png
data\processed\figures\acf_pacf_total.png
data\processed\figures\acf_pacf_via_aerea.png
data\processed\figures\acf_pacf_via_maritima.png
data\processed\figures\acf_pacf_via_terrestre.png
data\processed\figures\descomposicion_región_america_del_centro.png
data\processed\figures\descomposicion_región_america_del_norte.png
data\processed\figures\descomposicion_región_europa.png
data\processed\figures\descomposicion_total.png
data\processed\figures\descomposicion_via_aerea.png
data\processed\figures\descomposicion_via_maritima.png
data\processed\figures\descomposicion_via_terrestre.png
data\processed\figures\prediccion_región_america_del_centro.png
data\processed\figures\prediccion_región_america_del_norte.png
data\processed\figures\prediccion_región_europa.png
data\processed\figures\prediccion_total.png
data\processed\figures\prediccion_via_aerea.png
data\processed\figures\prediccion_via_maritima.png
data\processed\figures\prediccion_via_terrestre.png
data\processed\figures\serie_región_america_del_centro.png
data\processed\figures\serie_región_america_del_norte.png
data\processed\figures\serie_región_europa.png
data\processed\figures\serie_total.png
data\processed\figures\serie_via_aerea.png
data\processed\figures\serie_via_maritima.png
data\processed\figures\serie_via_terrestre.png
data\processed\tables\analisis_comparativo.csv
data\processed\tables\diagnostico_series.csv
data\processed\tables\estadisticas_viajero.csv
data\processed\tables\modelos_región_america_del_centro.csv
data\processed\tables\modelos_región_america_del_norte.csv
data\processed\tables\modelos_región_europa.csv
data\processed\tables\modelos_total.csv
data\processed\tables\modelos_via_aerea.csv
data\processed\tables\modelos_via_maritima.csv
data\processed\tables\modelos_via_terrestre.csv
data\processed\tables\resumen_calidad.csv
data\processed\tables\resumen_modelos.csv
data\processed\tables\resumen_series.csv
data\processed\tables\series_mensuales.csv
data\processed\tables\top_fronteras.csv
data\processed\tables\top_paises.csv
data\processed\tables\top_regiones.csv
data\processed\tables\top_vias.csv